

ОБУЧЕНИЕ КОМПОЗИЦИИ ОПЕРАТОРОВ В СЕТЯХ КОЛМОГОРОВА-АРНОЛЬДА ДЛЯ ОБНАРУЖЕНИЯ МУЛЬТИПЛИКАТИВНЫХ ЗАВИСИМОСТЕЙ

Шепелев Д. И., Демяненко Я. М.

ФГАОУ ВО «Южный федеральный университет»,
Институт математики, механики и компьютерных наук
им. И. И. Воровича

E-mail: dshepelev@sfnedu.ru, demyana@sfnedu.ru

Методы глубокого обучения, несмотря на высокую способность аппроксимировать сколь угодно точно любую зависимость, обладают низкой интерпретируемостью. Сети Колмогорова-Арнольда (KAN) предложены как альтернатива многослойным полносвязным сетям, заменяющая линейные веса на обучаемые одномерные функции, что повышает прозрачность модели за счет возможности визуализации этих функций [1]. Однако оригинальная архитектура KAN сохраняет аддитивную природу теоремы Колмогорова, ограничиваясь суммированием функций активации и моделируя мультипликативные взаимодействия между признаками только после явного задания присутствия перемножения двух операндов при инициализации модели [2]. В данной работе предлагается расширение KAN путем введения механизма разбиения операндов на группы произведения и сложения после сплайн-преобразования (Рис. 1), что позволяет сети не только адаптировать функции активации, но и синтезировать композиции операций сложения и умножения.




Рис. 1. Архитектура KAN с обучаемыми операциями

В рассматриваемой модификации слоя KAN суммирование по всем входам заменяется гибкой схемой: входные нейроны распределяются по G группам, где $G = \left\lfloor \frac{d_{in}}{2} \right\rfloor + 1$. $\left\lfloor \frac{d_{in}}{2} \right\rfloor$ групп предназначены для мультипликативной комбинации операндов, и дополнительная группа выделена под опе-

ранды сложения. Такое количество групп гарантирует, что в каждой мультипликативной группе потенциально может оказаться не менее двух операндов. Для каждого выходного нейрона o вводится тензор логитов $l_{i,o,g} \in \mathbb{R}$, где $g = 1, \dots, G$. Логиты преобразуются в вероятность принадлежности i -го входа к группе g с помощью softmax с температурой τ :

$$p_{i,o,g} = \frac{\exp\left(\frac{l_{i,o,g}}{\tau}\right)}{\sum_{g=1}^G \exp\left(\frac{l_{i,o,g}}{\tau}\right)}.$$

При $\tau \rightarrow 0$ распределение по группам стремится к дискретному виду.

Обозначим $\widetilde{y}_{i,o}$ – вклад i -го входа в o -й выход после сплайн-преобразования и масштабирования. Для мультипликативных групп $g = 1, \dots, G - 1$ вклад группы формируется как «вероятность произведения» значений $\widetilde{y}_{i,o}$ тех входов, которые попали в данную группу. Для расчета градиентов в условиях произведения и сохранения знаков используется гладкая аппроксимация умножения:

$$\begin{aligned} term_{i,o,g} &= 1 - p_{i,o,g} + p_{i,o,g} \cdot \widetilde{y}_{i,o}, \\ prod_{o,g} &= \prod_{i=1}^{d_{in}} term_{i,o,g}. \end{aligned}$$

При условии, что все $p_{i,o,g}$ равны нулю (вход не принадлежит группе), $term_{i,o,g} = 1$ и не влияет на произведение. Если $p_{i,o,g} = 1$ (вход полностью отнесён к группе), то $term_{i,o,g} = \widetilde{y}_{i,o}$, и выражение становится произведением выбранных входов. Для аддитивной группы операндов, где $g = G$ вычисляется взвешенная сумма:

$$sum_o = \sum_{i=1}^{d_{in}} p_{i,o,G} \cdot \widetilde{y}_{i,o}.$$

Итоговый выход o -го нейрона является суммированием вкладов всех групп:

$$z_o = sum_o + \sum_{g=1}^{G-1} prod_{o,g}.$$

Архитектура была протестирована на задачах регрессии для формул:

$$\begin{aligned} y &= x_0 x_2 + x_4 \sin 2\pi x_3 + x_2, x \in [-1, 1], N_{samples} = 1000, \\ y &= \frac{x_0}{x_1}, y = \frac{x_0}{x_1} + \frac{x_2}{x_3}, y = x_0/x_1/x_2/x_3, x \in [0.1, 1], N_{samples} = 1000. \end{aligned}$$

Первый пример призван продемонстрировать способность модели распределять операнды по группам. Примеры с делением покажут возможность применения модели для нахождения обратных зависимостей между

величинами, например, для задач, где требуется найти нормирующий признак.

Обучение модели осуществляется путем минимизации составной функции потерь, включающей ошибку регрессии и регуляризационные слагаемые, направленные на повышение интерпретируемости и разреженности. В качестве оптимизатора используется Adam с экспоненциальным затуханием скорости обучения. Все эксперименты проводятся с фиксированными параметрами: начальная скорость обучения 0.1, количество эпох 200, размер мини-батча 64. Для обеспечения плавного перехода от вероятностного распределения операций к почти дискретному, а также для стабилизации обучения, применяется экспоненциальное уменьшение параметров модели:

$$\tau(t) = \tau_{start} \left(\frac{\tau_{end}}{\tau_{start}} \right)^{\frac{t}{T}}, \tau_{start} = 2.0, \tau_{end} = 0.1$$

Для дополнительного контроля дискретности структуры группирования операндов введена регуляризация энтропия распределения операций по группам, усредненная по всем слоям:

$$H_{ops} = -\frac{1}{d_{in}d_{out}} \sum_{i=1}^{d_{in}} \sum_{o=1}^{d_{out}} \sum_{g=1}^G p_{i,o,g} \log(p_{i,o,g} + \varepsilon),$$

$$\lambda(t) = \lambda_{start} \left(\frac{\lambda_{end}}{\lambda_{start}} \right)^{\frac{t}{T}}, \lambda_{start} = 10^{-2}, \lambda_{end} = 1.0.$$

Для оценки результатов обучения была построена визуализация структуры моделей (Таблица 1).

Таблица 1. Результаты обучения KAN + обучаемы операции

$y = x_0x_2 + x_4\sin 2\pi x_3 + x_2$	$y = \frac{x_0}{x_1}$	$y = \frac{x_0}{x_1} + \frac{x_2}{x_3}$	$y = \frac{\frac{x_0}{x_1}}{\frac{x_2}{x_3}}$

Предложенная модификация позволяет сети автоматически обнаруживать, какие комбинации входных признаков следует перемножать, а какие – складывать, что повышает интерпретируемость модели. Экспери-

менты показывают, что такой подход успешно выделяет мультипликативные структуры в задачах символьной регрессии и делает внутреннее представление модели более прозрачным для исследователя.

Литература

1. Liu Z. et al. Kan: Kolmogorov-arnold networks //arXiv preprint arXiv:2404.19756. – 2024.
2. Liu Z. et al. Kan 2.0: Kolmogorov-arnold networks meet science //arXiv preprint arXiv:2408.10205. – 2024.